ChatGPT

# 执行摘要

- **多模态科学基础模型崛起**：近年来 AI 在材料、蛋白等领域诞生了多模态大型基础模型。如 DeepMind 的 GNoME 模型利用图神经网络在材料科学中一次性预测出 **220万** 新晶体，其中 **38万** 种被判定非常稳定，可作为未来超级计算机、高效电池等技术的候选材料 [1]。这相当于增加了过去800年才能积累的材料知识量 [2]。又如 2024 年发布的 AlphaFold3 模型，不仅可高精度预测单个蛋白质结构，还能预测蛋白质与 **其他分子**（蛋白或小分子药物）的复合构象 [3]。AlphaFold3 已开放源代码供学界使用，并克服了先前代码未开放导致的科研复现难题 [4] [5]。OpenFold 等开源项目也在推动基础模型开源化，例如 2024 年 Nature Methods 报道的 OpenFold 是 AlphaFold2 的完全开源可训练实现，利用超算重新训练以匹敌原版精度 [6]。OpenFold 还被 Meta 用于预测 6 亿多个微生物蛋白结构，显著扩充了蛋白结构数据库 [7]。

- **函数调用与闭环优化成为新范式**：为了让 AI 真正执行科学实验和优化流程，研究者开发了 **工具调用**能力和**闭环优化**框架。一方面，语言模型通过训练学会使用 API/工具完成复杂指令。例如 2023 年提出的 ToolBench 数据集收集了 **16,464** 个现实 API，让 ChatGPT 生成涉及它们的指令及解题步骤，并由此微调出 ToolLLaMA 模型，实现对 **49类工具**的调用，解决复杂多工具任务，性能直逼 ChatGPT [8] [9]。另一方面，在科研实验中引入**强化学习（RL）闭环优化**，让AI主动规划并实施实验以优化目标。虚拟平台 ChemGymRL 提供了模拟化学实验的开放环境（如反应台、蒸馏台等），RL 智能体可在其中反复试验操作以习得高效实验步骤 [10]。材料领域则由 Meta 等引领，将 AI 与机器人实验室结合：2024 年发布的 Open Catalyst 实验平台（OCx24）在数月内 **自动筛选并实测了 525 种新电催化材料**，生成了开源数据库用于弥补AI模型对实验数据的需求缺口 [11]。这些实践表明工具使用和RL闭环让AI从“提出方案”进化到**自主执行和优化**科学流程。

- **Agentic 科研工作流与评测标准**：面向端到端的“AI 科学家”，Agent式工作流和评测正在成形。ScienceAgentBench 基准选取了数据驱动科学发现流程中的 102 项真实任务，对现有语言智能体逐项评估，结果显示即使最强模型**独立完成率仅32.4%**，借助专家知识也仅34.3%，OpenAI新模型提升至42.2%但代价昂贵 [12]。这凸显了当前**科研智能体能力不足**，需要更精细的训练和架构。为此，近期兴起了**Planner-Executor-Verifier** 等多代理协作架构 [13]：由**规划 Agent**拆解任务，**执行 Agent**调用工具或代码完成步骤，**验证 Agent**审查结果并反馈，从而形成闭环提高可靠性。这类架构已体现在如 DeepMind 的 AlphaEvolve。AlphaEvolve 是 2025 年发布的 Gemini 大模型驱动的进化式编码 Agent，结合 LLM 的创造力和自动评价器，以演化算法不断改进方案 [14]。它成功发现了打破56年纪录的矩阵运算新算法，并优化了谷歌数据中心调度（使全球算力利用率提高0.7%）、芯片设计和 AI 模型训练等多项实际问题 [15] [16]。类似地，学术界尝试用多个 LLM 代理组成**“模拟科研团队”** (Simulated Research Team)：有研究让GPT-4代理阅读论文方法和数据字典，尝试复现阿尔茨海默症研究的结论，结果约**53.2%**的关键发现被复现，但也因为实现细节缺失等导致部分失败 [17]。这证明了Agent自主科研的潜力，同时也揭示了其**对轨迹数据、失败案例和行为反馈的强依赖**——智能体需要大量带标注的决策轨迹来学习何为正确步骤，从错误中汲取教训，并在训练中融入人类评价信号来塑造行为。

- **展望与机会**：综合来看，AI-for-Science 正在从感知预测（如结构预测）拓展到决策执行（如实验规划）。多模态大模型提供了跨领域基础能力，但要让AI自动完成科学发现，还必须训练其调用工具和在环境中试错优化。标准化实验描述语言（如 AutoProtocol、LAP）和开源工具库（如 ToolBench API集合）正在解决**接口问题**，方便AI理解实验操作并执行。而新的评测基准与多Agent框架则在探索**可靠性与协作**，帮助量化智能体的真实科研能力。未来机会在于：融合多模态知识与操作的通用科学智能体、结合符号规划与学习的混

合智能、更加开放的实验数据共享生态，以及人机协同的高效科研范式。抓住这些趋势将有助于研发**下一代“AI科学家”**，在材料、制药、能源等关键领域加速突破。

## 模型技术演进路线图

图：多模态科学模型与自主*Agent*技术发展路线图示意。从静态预测（左）到闭环实验（中）再到自主科研智能体（右），*AI*模型能力在不断拓展。左图为 *GNoME* 模型的“双管道+主动学习”架构示意，它通过结构生成和组分随机探索产生新晶体并用*DFT*验证反馈，提高材料稳定性预测准确率 [18] [19]。右图为 *AlphaEvolve Agent* 框架示意，展示了提示组装、*LLM*生成方案、自动评估筛选、进化迭代的循环，用于算法创新 [20]。（图片来源：*DeepMind* [21] [20]）

- **2023** – 多模态基础模型涌现，侧重结构与属性预测：以 AlphaFold2 开源及改进版本(OpenFold)为标志，AI准确预测蛋白质结构达到前所未有高度，促使学界成立 OpenFold 联盟用超算重训模型 [6]。材料科学中，DeepMind 提出 GNoME 模型，用图网络+主动学习大幅提升新材料（晶体）发现速度 [2]。Meta 发布 OpenCatalyst 2020数据集，推动催化材料模拟，加速图模型在催化领域应用 [22]。这一年AI-for-Science以**感知类任务突破**（结构、能量预测）为主。

- **2024** – 模型能力扩展与开源，加速实验闭环融合：AlphaFold3 发布，支持蛋白–配体/蛋白相互作用预测，被誉为“巨大飞跃”，并在争议后开放源码 [4] [5]。OpenFold 在Nature Methods发表，成为可训练的开源蛋白结构模型平台 [6]。材料方向，GNoME 登上Nature，预测出 380k 种稳定晶体并公开数据 [1] [23]。同年出现实验自动化新标准 LAP [24]，以及 AutoProtocol 被更多机构采用，规范实验DSL描述 [25]。ToolBench 提供大规模**工具调用数据**，衍生出 ToolLLaMA 模型验证了开源LLM经微调可获接近专有模型的工具使用水平 [9]。另一方面，ChemGymRL 等模拟环境推出，使强化学习算法开始用于**数字化学实验**探索 [10]。DeepMind 等探索 Agent 方案：如 AlphaDev（通过RL发现新排序算法）和 AlphaTensor（RL发现矩阵算法）等前序项目 [26]，奠定了将大型模型与搜索优化结合的基础。

- **2025** – 自主*Agent*崛起与科学*AI*闭环成型：以 AlphaEvolve 为代表，自主Agent首次展现超越人类专家设计算法的能力，在实际系统中部署（数据中心调度、TPU电路优化等）并带来持续收益 [27] [28]。ScienceAgentBench 等评测公开，量化了现有模型在科学任务自动化中的短板 [12]。模拟科研团队（SRT）试验出现，尝试多智能体协作复现科研成果，虽有进展但也揭示局限 [17]。学界进一步提出 Planner-Executor-Verifier 等 **Agent架构范式** [13]，并重视失败案例和反馈标注的重要性。例如有工具推出可形式化描述实验失败点（如 Oops 语言） [29]，帮助AI学习“如何更好地失败”。总体而言，2025 年标志着AI从辅助分析工具向**自主研究参与者**的角色迈进，闭环的AI科研工作流开始形成雏形。

## 多模态科学基础模型训练范式拆解

多模态科学模型指能理解处理多种科学数据形式（序列、分子图、晶体结构、实验结果等）的通用大模型。典型模型包括材料科学的晶体预测模型、分子性质模型，以及生物领域的蛋白质结构与功能模型。它们的训练范式具有以下特点：

- **大规模多源数据汇集**：这类模型训练需要融合不同类型的大数据。例如 GNoME 模型训练用到了 Materials Project 等开放晶体结构数据库及其计算稳定能量作为监督信号 [30] [19]。AlphaFold 系列模型则利用了数百万计的蛋白质序列、结构对，其中序列来自 UniProt 等数据库，结构来自PDB和模板库，以及进化共变信息。OpenCatalyst 项目汇集了超过 **130万** 对催化剂表面-吸附物的DFT仿真数据，用于训练图神经网络预测

吸附能 [31]。随着项目推进，又不断加入新的数据源（如 OC22/OCx24 将真实实验结果纳入）。这种海量多源数据提供了**广覆盖的分布**，让模型学习普适的科学表征。

- **自监督预训练与专用任务微调**：为了在多模态数据上学到有用表征，常采用自监督预训练。例如 OpenFold 不仅复现AlphaFold2的监督训练，也探索结合"蛋白语言模型"对海量未注释序列做预训练，再适配结构预测任务 [32]。在材料领域，Open MatSci ML 工具包提出对晶体点云数据进行合成变换预训练，再迁移到下游物性预测 [33] [34]。预训练提供通用表示后，通过少量有标签数据微调即可在特定任务上达SOTA效果，体现**"基础模型+微调"**范式。比如 AlphaFold2 微调出 AlphaFold-Multimer 专门预测蛋白复合物结构 [35]；OpenFold 也可在新数据上再训练以提升特定蛋白类别精度 [36]。

- **模型结构与能力**：多模态科学模型通常结合**领域先验**与**深度学习**架构。AlphaFold系列使用了掩蔽语言模型加多轨注意力网络来融合序列和进化信息，再借助结构优化模块输出3D坐标 [37]。GNoME 则采用 **图神经网络（GNN）**直接对晶体结构图建模，其架构对晶格对称性不变性进行了特殊设计，并通过主动学习循环不断提高预测精度 [30] [19]。OpenCatalyst 2023 的顶尖模型融合了三维等变图网络，对吸附体系的原子几何关系建模良好 [38]。这些模型经过大数据训练后展现出**跨任务泛化**能力：如 GNoME 一经训练即可用于预测任意元素组合的稳定性，不局限于训练见过的化合物 [39] [40]。AlphaFold2 推理时可对几乎任何蛋白序列给出结构预测，包括许多未实验解析的蛋白 [5]。这类基础模型为科学提供了**通用工具**，显著加快了候选材料、分子和靶标的发现速度。

- **数据与算力需求**：训练此类模型往往需要**巨量算力**。例如 OpenFold 团队指出训练一个AlphaFold2级别的模型需约100块GPU参与 [41]；相比之下GPT等语言模型需要上万GPU，因而生物大模型算力需求虽高但仍在可承受范围 [41]。在材料模拟中，引入主动学习循环虽然减少了所需的DFT标签数量，但每轮仍需算力验证模型产出。GNoME 报道其主动学习将稳定性预测准确率从50%提至80% [42]（MatBench基准），但过程结合了数万次DFT计算作为反馈，这实质上消耗了巨大算力 [19] [42]。因此，多模态基础模型的研究推动了**科研算力基础设施**的发展，包括大型超算集群和云计算在科学AI训练中的应用。

- **模型能力边界与升级方向**：尽管已有突破，这些模型仍有局限。例如 AlphaFold 无法预测蛋白动力学和配体反应动力学；GNN在材料缺陷、非平衡态预测上尚待加强。2025 年的 AlphaFold3 正在迈向 **分子间复杂相互作用**和**功能预测**（如突变效应）等方向 [43] [5]。OpenCatalyst 也在探索催化反应路径的自动探索，而非静态吸附能量。未来，多模态模型可能融合**文本、图像**等模态（如阅读文献、解析显微镜图像）以获得更全面的科学认知。此外，将这些模型与机器人实验整合，实现**候选生成→实验验证→模型更新**的循环（闭环科学），也是重要演进方向。GNoME 与伯克利实验室合作的论文证明了这一点：AI预测+机器人合成可以 **每天自动制备2种以上新材料**，远超人工效率 [44]。这预示着多模态基础模型将成为自动化科学研究的"大脑"，指导后续实验和发现。

## 函数调用与闭环优化训练范式拆解

本部分聚焦让AI学会**调用外部函数/工具**以及**在环境中试错优化**，使其能够闭环地完成实验和分析任务。这涉及训练方法上的创新，包括指令微调、工具增强学习和强化学习优化等：

- **实验流程 DSL 与自动化接口**：科学实验往往需要精确控制实验步骤和仪器。为让AI生成可执行的实验方案，必须使用标准化的实验描述语言（DSL）。**AutoProtocol** 是此领域早期标准之一，采用人机可读的严格语法（JSON格式）描述实验操作（移液、培养、测量等），确保指令**精确、无歧义，机器和人都能理解** [25]。2023 年推出的 **LAP (Laboratory Automation Protocol)** 格式则进一步规范了实验脚本编写，并配套开源协议仓库，旨在提升合成生物学领域的工作流程效率 [24]。训练AI时，会将实验任务和目标转表达为DSL方

案生成问题。例如给定一个化学合成目标，用 AutoProtocol DSL 写出具体操作序列。模型需要在训练中学习 DSL 语法及**实验知识约束**。为此，可收集公开的实验protocol作为训练语料，或利用规则引擎生成DSL实例来微调模型。随着 Ginkgo Bioworks、Strateos 等公司积累了大量自动化实验程序，预期将出现规模化的实验DSL数据用于训练。掌握DSL使模型能"讲实验机器的语言"，实现对物理实验的下达指令能力。

- **Tool-Calling 指令微调**：通用LLM经过基础训练后，对调用工具/API通常缺乏技能，需要专门微调。如前述 **ToolBench** 项目采用 **指令微调(instruction tuning)** 的策略：构造包含调用真实工具的指令-响应对，让模型在模拟情境下学习**何时及如何调用API**。ToolBench团队自动收集了 1.6 万余个RESTful API并分类，然后令ChatGPT生成涉及这些API的多样用户需求及解决方案（包括需要依次调用多个工具的复杂任务）[8]。每个生成示例都附有正确的工具使用序列作为示范。通过这些数据对开源大模型（如 LLaMA）微调，模型学会了阅读指令并**产出带函数调用的执行方案**。值得注意的是，他们还给模型配备了**神经API检索器**，可根据指令语义从庞大API库中匹配相关工具[9]。这解决了开放环境下API选择的问题，让模型在推理时能先检索再调用。ToolBench 的结果显示，微调后模型（ToolLLaMA）在看过的工具域和全新工具域都能正确调用API执行任务，表现与ChatGPT相当[9]。此类训练范式也应用于浏览器操作、数据库查询等场景，使模型具备**读写网页、查表**等特定技能。总的来说，Tool-Calling 微调让LLM从纯文本对话扩展为 **可以调用万物**的助手，为闭环任务奠定基础。

- **强化学习优化（RL in the Loop）**：在需要连续决策、观察反馈、逐步优化的科学任务中，引入强化学习能让AI形成闭环优化策略。一个典型例子是在**虚拟实验环境**中训练智能体优化化学反应。ChemGymRL 提供了一系列模拟环境（遵循 OpenAI Gymnasium接口），包括反应Bench、萃取Bench、蒸馏Bench等，每个环境都有定义明确的状态（如试管中化合物浓度）、动作（加热、加入试剂等）和奖励（如产物收率）[45][10]。研究者可以设定某种目标产物的合成路线优化问题，让RL代理在ChemGymRL中不断试验不同操作序列。通过Q学习、策略梯度等算法训练，代理逐渐学会**高效达成目标的实验操作序列**[46]。这样的RL策略在模拟中验证有效后，可迁移到真实机器人实验室执行，形成"AI科研自动导航"能力。除了化学，生物实验（例如发酵工艺优化、细胞培养参数优化）也可以用类似方法。关键在于设计合理的模拟器和奖励函数。近期还有工作将RL用于材料设计的闭环，例如训练智能体选择下一组实验参数以最大化某材料性能。这类**闭环RL优化**通常需要大量试验探索，因而模拟器精度和并行实验能力很重要。Meta的OCx24项目虽然主要是高通量筛选实验，但也体现了闭环理念：AI模型预测最具前景的催化剂配方，机器人迅速实验验证，将结果回馈模型并选择下批实验[11][47]。未来可预见RL将与机器人实验深度结合，让AI在真实环境中通过试错不断改进科学成果。

- **人类反馈与安全约束**：AI 在调用工具和自动实验时，加入**人类反馈信号**和安全约束训练十分关键。一方面，借鉴 RLHF（人类反馈强化学习）的做法，可让人或专家对模型决策（如生成的实验方案、选择的工具序列）进行评估打分，用作奖励信号微调模型策略，从而更符合人类期望。特别是在生命科学实验中，某些错误操作可能造成危险或代价高昂，因此应在训练中加入对于**失败案例的惩罚**。近期有语言如 "Oops" 提出用于形式化表示实验中可能出现的失败和异常[29]，这样AI能在学习时明确哪些行为是错的、为何错，以及如何快速检测失败。另一方面，在工具使用上给模型施加**约束**也很重要。例如要求模型必须先调用某些诊断API检查再执行关键操作，或限定其只能访问白名单内的安全工具[48]。训练时可通过添加约束后的对话示例、以及利用"监督惩罚"机制（如输出不合规指令时给予负奖励）来实现。以上措施能减少AI在闭环操作中犯严重错误的概率，提高其可靠性。总的来说，函数调用与闭环优化范式的训练，需要综合考虑**数据驱动学习**（海量工具/API示例）、**环境交互学习**（模拟+RL）、以及**反馈纠偏**（人类和规则约束引导），三管齐下才能打造一个既能自主行动又安全可信的科学AI代理。

## Agent 工作流微调范式拆解

Agent式模型（自主智能体）是指具备规划、执行、反思能力，能自主完成多步任务的AI。在科学领域，这意味着AI能够像科研人员一样制定研究计划、调用工具实验、评估结果并调整方案。要训练出这样的Agent，需要在基础模型之上进行专门的**多段式微调**和**策略优化**：

- **角色分工与多智能体协同**：单个大型模型难以包揽所有环节，因此出现了**多Agent分工**范式。常见架构包括**规划器-执行器-验证者 (Planner-Executor-Verifier)** 模式 [13]。在训练时，可以给予模型不同角色指令，让它们各司其职协作完成任务。例如，用一个LLM学做"规划助手"，输入科研目标输出详细计划步骤；另一个LLM学做"实验员"，根据计划调用工具/写代码执行；再用一个LLM做"审查官"，读取执行结果与目标比对给出反馈。通过在大量模拟任务上重复这种交互，模型逐渐掌握**角色内技能**及**跨代理沟通**。最近的一些框架（如 LangChain Autogen、MetaGPT 等）提供了方便的接口来训练和运行多代理系统 [49]。多Agent协同的训练重点在于让每个代理都经过指令调教，并在交互中学会遵循协议、共享记忆等 [50] [51]。比如，为避免两个Agent重复劳动或互相矛盾，训练数据中要包含良好协作范例，以及不恰当协作的纠正示例。ScienceAgentBench 中一些任务也可以拆分子任务来测试多Agent配合能力 [52]。总之，Agent微调常用**分角色训练**，提升复杂任务成功率。

- **示范轨迹和行为克隆**：要让Agent掌握完整任务流程，**高质量示范轨迹数据**非常宝贵。轨迹指完成任务的一系列对话、操作序列。例如，一个"设计化学实验"的轨迹可能包括：Agent提问实验需求→Agent检索文献→Agent规划步骤→Agent生成AutoProtocol→Agent预估可能结果→结束。研究者可以人工或借助强模型生成这样的示范脚本，并标注每一步的合理性。通过**行为克隆**(Behavior Cloning)训练，Agent可以模仿这些专家轨迹。在科学领域，公开的**实验笔记本**、**机器人实验日志**都是潜在的数据源。如果缺乏真实数据，也可以利用当前最强模型来构造。例如用GPT-4模拟一个完整科研对话流程（让它扮演多个角色自洽对话），生成"理想轨迹"供较小模型学习。ScienceAgentBench 提供的 102 个任务，其 **参考解答**（以Python程序形式）和相应的对话思路，其实也是一种轨迹示例 [53] [54]。这些可用于训练模型如何逐步求解科学问题。需要注意的是，示范应涵盖**失败情况**，让Agent也了解哪些策略行不通以及如何调整。例如在轨迹中有意展示"第一次实验失败，Agent 分析原因后改进方案"的过程，以训练其 **容错与改进**能力 [55]。通过模仿学习，Agent能习得完整的问题求解流程和遇挫折时的调整行为，为后续自主性奠定基础。

- **自我反馈与强化微调**：有了示范初步训练后，可进一步采用**生成-评估-反馈**循环让Agent自我改进。这类似人类在实践中反思提高的过程。一种方法是让Agent在模拟环境自主反复尝试任务，并使用一个**Critic模型**或规则来评估每次尝试的质量，然后根据评分通过**强化学习**调整策略。DeepMind 的 AlphaEvolve 就体现了这种思想：它由多种 Gemini LLM 生成算法代码，再由自动评估器验证性能，将得分反馈进**进化算法**筛选出更优的方案继续迭代 [14] [56]。这种基于遗传进化或强化学习的自我反馈，使Agent能跳出训练数据分布，发现**全新解法**。AlphaEvolve 成功发现了前所未有的优化算法证明了自我提升的威力 [15] [57]。在一般科研Agent训练中，也可应用类似思路：例如让Agent尝试解一道科学难题，如果失败，就让它读自己的解题记录，找出错误原因，再尝试改进（类似 Chain-of-Thought+ReAct+Reflexion 方法 [58] [59]）。这种**自我监督**可通过奖励模型打分或对比最终是否正确来实现。OpenAI等提出的"自我调试/self-debug"框架在ScienceAgentBench评测中就有效提高了一些任务成功率 [60]。因此，Agent微调后期往往结合**RL微调（RLFH）**或**进化策略**，让模型在模拟科研环境中不断试错、反思，最终策略稳定收敛到较优水平。

- **失败案例和人类评分融入训练**：Agent 的决策空间远比单步问答复杂，训练中充分利用失败案例和人评是提升可靠性的关键。首先，应建立**失败库**，收集Agent执行过程中常见的错误类型（如逻辑错误、工具调用失败、推理死胡同）。将这些失败案例加入训练数据，并在后面接上正确行为的示范（即告诉模型"在这种情况下，正确的做法是…"）。这种对比学习能显著减少模型重复同样错误。如某Agent总是忘记控制变量导致

实验失败，那么提供反例“因为未对照，结果无效”及修正示范，可让模型下次注意。ScienceAgentBench的结果就强调了当前模型对失败缺乏记忆，很多任务反复尝试仍错 [12] 。通过训练让模型**识别失败迹象**（例如实验结果异常、不符合物理规律等），它可以更早止损调整。其次，引入**人类评价**来 fine-tune：让科学家对Agent完成复杂任务的过程打分或指出不足，并将这些人工反馈融入损失函数，类似RLHF。在AlphaEvolve等闭环系统中，虽然主要靠自动指标，但在更开放的科研探索中，人类专家的直观判断仍很有价值，可指导Agent朝更有创新性的方向探索而非局限于过拟合训练目标 [61] [62] 。最后，还可以利用**评测基准**本身作为训练辅助，比如让模型在ScienceAgentBench未通过的任务上进一步微调学习官方参考解，让其弥补弱点。一项针对多LLM代理的研究指出，小模型单独学不好工具用法，但如果参考了GPT3.5执行轨迹标注，再训练，可以明显提升 [63] 。这说明有效利用“大模型示范 + 人类校验”得到的高质量行为数据，可以显著提高Agent性能。归根结底，Agent微调是一个持续反馈改进的过程，需要营造一个让模型**不断学习自身错误**并从人类处汲取经验的训练闭环。

## 数据类型 × 场景 × 增速预测

| 数据类型 | 典型应用场景 | 增长趋势（2025起） |
|---|---|---|
| **晶体/材料结构与性能数据** | 新材料发现（稳定性预测、催化剂设计） | 高速增长：AI预测助力下，新材料数据库扩容<br>（如已知稳定晶体数由5万增至42万 [39] ；未来每年料翻倍） |
| **蛋白质及复合物结构数据** | 蛋白工程、药物筛选 | 高速增长：AlphaFold数据库已涵盖2亿蛋白结构，AlphaFold3 开启复合物预测 [5] ；<br>预计每年新增上亿结构，包括蛋白-配体复合物 |
| **实验协议与过程日志数据** | 实验自动化（机器人实验室） | 中速增长：更多实验以标准DSL记录，每年实验步骤数据量~30%↑；<br>随着LAP等普及，大型开放协议库（如 LAPRepo）逐步形成 [24] |
| **工具/API使用交互数据** | LLM工具增强（检索、计算、控制） | 高速增长：通过自动生成和开源贡献，ToolBench类数据规模迅速扩大；<br>工具接口每年增加数千个，新交互样本数年增长>50% |
| **Agent决策轨迹和多模态反馈** | 科研代理（自动推理、多步实验） | 中高速增长：目前公开轨迹数据有限（如ScienceAgentBench 100余条任务) [53] ；<br>但随着更多基准和模拟环境发布，预计每年增长数倍，涵盖更多学科任务 |
| **失败案例与行为评价数据** | 模型校准（安全、可靠性训练） | 中速增长：社区逐步重视公开失败教训（如MISR失败集），组织挑战赛收集错误案例；<br>人类评价数据随RLHF扩展，每年增长~30%，重点覆盖关键领域 |

表：*AI-for-Science* 的关键数据类型、应用场景及未来数据增速预测。总体而言，由于模拟和*AI*本身可产生海量候选（如 *GNoME* 一次生成*220*万材料数据 [1] ），科学数据正在指数级膨胀；而实验验证数据相对增速较缓但逐步提速（自动化高通量技术贡献显著）。各类数据的累积将进一步反哺模型训练，提高*AI*科研智能体的能力。

## 总结与建议

综上，2025 年以来 AI-for-Science 领域在模型、算法和数据三个层面都出现了显著的新趋势：大型**多模态基础模型**打破单一模态局限，成为跨材料、生物等领域的通用预测工具；**函数调用与闭环优化**让AI从“会思考”进化到“会动手”，能够对接实验仪器和软件工具实现自主试验；而**Agent式工作流**则描绘了未来 AI 科学家的雏形，通过多智能

体分工与反馈学习，AI有望胜任部分科研任务的端到端自动化。但是我们也清醒地看到，当前的科研AI距离完全自主可靠地发现创新尚有明显差距 [12] 。为推动这一领域继续前进，我们提出以下建议和展望：

- **加强数据开放与标准化**：无论是模型训练还是Agent微调，都需要海量高质量数据支撑。建议政府、科研机构加速推进科学数据的开放共享，特别是实验过程数据、失败结果数据的公开。这类数据过去往往尘封于实验室笔记本，但对AI学习尤为宝贵。此外，推动实验DSL（如 AutoProtocol/LAP）的标准统一和普及，将方便社区积累可被AI直接使用的实验脚本知识库。标准化的数据格式和接口也有利于不同实验平台、AI代理之间的互操作。

- **发展人机协同的闭环科研范式**：短期内，“AI科学家”最佳的形态可能是与人类科学家协作而非完全取代。AI代理可以在繁琐的实验规划、文献检索、数据分析上提供建议并执行初步尝试，而人类研究者负责提出有价值的问题、判断AI给出的方向并进行创造性的决策。因此应设计以人为中心的AI科研工作流，让研究者方便地指导AI agent、介入关键节点并纠正偏差。这需要良好的用户界面和可解释性工具，例如可视化Agent的决策树、提供失败原因报告等，增强人对AI的掌控感和信任度。

- **重点突破关键瓶颈领域**：结合当前进展，材料科学、生命科学中的若干瓶颈问题可以作为AI-for-Science突破口。例如新药发现中的分子设计-合成-测试闭环，完全可以用AI代理来大幅提速（虚拟筛选候选->机器人合成->高通量测试->AI分析反馈）。又如气候能源领域的新材料、新催化剂筛选，已经在OCx项目中初显成效，未来可进一步拓展到更复杂的化学空间。在这些“高价值/高数据量”的领域取得成功范例，将极大证明AI科研闭环的价值，吸引更多投入。

- **完善评测体系与安全监管**：建议建立更加完善的AI科研智能评测体系，扩展ScienceAgentBench涵盖更多学科、多步流程，并制定统一指标衡量。例如针对化学合成AI，可有标准的成功率、收率提升等指标；对生物实验AI，可评估其假设生成和验证能力。同时，要有针对AI自主实验的安全伦理指南，明确禁止AI在无监督情况下进行高风险实验，并对AI给出的实验方案进行合规审查（就像FDA对新药实验审批一样的机制）。只有在安全可控的前提下，AI才能被更广泛地信任用于科学研究。

- **跨学科人才与研究投入**：鼓励计算机科学家与各领域科学家紧密合作，培养既懂AI又懂专业科研的复合型人才。他们将是打造AI-for-Science应用的中坚。当前这一领域呈现出**产业与学术融合**的趋势，科技公司（如DeepMind、Meta）和顶尖实验室共同推动突破。建议各国科研资助机构设立专项项目，支持AI在基础科学中的应用研究，并搭建开放平台供学术和产业共享成果。抓住这个窗口期进行战略投入，有望在新材料、新药物甚至基础科学定律发现上取得颠覆性进展。

展望未来，AI-for-Science 正朝着让 **科学研究范式发生革命性变化**的方向快速迈进。从让机器学习掌握科学知识，到让机器主动提出并验证科学假设，这一路仍有挑战，但前景光明。谁能率先解决AI自主科研中的关键问题，谁就可能引领下一场科技浪潮。我们应当积极拥抱这一变革，推动AI与科学的深度融合，在确保安全与可靠的前提下，让智能机器成为人类探索未知的强大助手，共同开创科学发现的加速时代。 [12] [57]

---

[1] [2] [18] [19] [21] [23] [30] [39] [40] [42] Millions of new materials discovered with deep learning - Google DeepMind
https://deepmind.google/discover/blog/millions-of-new-materials-discovered-with-deep-learning/

[3] [4] [5] DeepMind makes AlphaFold3 open source | Mindplex
https://magazine.mindplex.ai/post/deepmind-makes-alphafold3-open-source

6 7 32 36 41 AI, Computation, and the Folds of Life
https://tacc.utexas.edu/news/latest-news/2024/08/13/ai-computation-and-the-folds-of-life/

8 9 [2307.16789] ToolLLM: Facilitating Large Language Models to Master 16000+ Real-world APIs
https://arxiv.org/abs/2307.16789

10 46 [2305.14177] ChemGymRL: An Interactive Framework for Reinforcement Learning for Digital Chemistry
https://arxiv.org/abs/2305.14177

11 47 Meta AI helps build experimental catalyst database
https://www.theengineer.co.uk/content/news/meta-ai-helps-build-experimental-catalyst-database/

12 53 54 60 [2410.05080] ScienceAgentBench: Toward Rigorous Assessment of Language Agents for Data-Driven Scientific Discovery
https://arxiv.org/abs/2410.05080

13 49 50 51 58 59 LLM Agents Replace Backend Logic—Too Good To Fail?
https://aicompetence.org/llm-agents-replace-backend-logic/

14 20 28 56 AlphaEvolve: A Gemini-powered coding agent for designing advanced algorithms - Google DeepMind
https://deepmind.google/discover/blog/alphaevolve-a-gemini-powered-coding-agent-for-designing-advanced-algorithms/

15 16 26 27 57 61 62 Google DeepMind’s AI Agent Dreams Up Algorithms Beyond Human Expertise | WIRED
https://www.wired.com/story/google-deepminds-ai-agent-dreams-up-algorithms-beyond-human-expertise/

17 55 [2505.23852] Large Language Model-Based Agents for Automated Research Reproducibility: An Exploratory Study in Alzheimer's Disease
https://arxiv.org/abs/2505.23852

22 31 33 34 38 Towards Foundation Models for Materials Science: The Open MatSci ML Toolkit
https://arxiv.org/pdf/2310.07864

24 The Laboratory Automation Protocol (LAP) Format and Repository: A ...
https://newsletter.x-mol.com/paper/1726734881654591488

25 Rhys Ormond | Autoprotocol
https://rhysormond.com/projects/autoprotocol/

29 [PDF] Oops: A Language for Formalizing Fallible Biological Protocols
https://www.biorxiv.org/content/10.1101/2025.06.17.660245v1.full.pdf

35 37 Accurate structure prediction of biomolecular interactions with AlphaFold 3 | Nature
https://www.nature.com/articles/s41586-024-07487-w?error=cookies_not_supported&code=0b841ee9-c1de-463d-bb11-7825cbf9e6e7

43 Google DeepMind CEO: AI-Designed Drugs May See Trials in 2025
https://www.pymnts.com/artificial-intelligence-2/2025/google-deepmind-ceo-ai-designed-drugs-coming-to-clinical-trials-in-2025/

44 GNoME's Impact on Industry - PreScouter
https://www.prescouter.com/2024/01/gnomes-impact-on-industry-how-to-avoid-a-kodak-moment/

45 ChemGymRL - GitHub
https://github.com/chemgymrl/chemgymrl

48 Top 100 AI Agent Interview Questions | by Sanjay Kumar PhD
https://ai.plainenglish.io/top-100-ai-agent-interview-questions-0b32d604a80f

52 Evaluating LLMs for Scientific Discovery: Insights from ... - Mindplex
https://magazine.mindplex.ai/post/evaluating-llms-for-scientific-discovery-insights-from-scienceagentbench

63 [PDF] Small LLMs Are Weak Tool Learners: A Multi-LLM Agent
https://aclanthology.org/2024.emnlp-main.929.pdf